

Использование нейронных сетей для прогнозирования фондового рынка

В наше время качественное прогнозирование финансовых рынков приобретает всё большую популярность. Связанно это, в частности, с быстрым развитием высоких технологий, а соответственно, и с появлением всё более совершенного инструментария анализа данных. К сожалению, столь привычный для большинства участников рынка технический анализ более не эффективен. Прогнозы на таких на основе экспоненциальных скользящих средних, осцилляторах или иных индикаторах не приводят к требуемому результату в большей степени из-за иррациональности экономики, так как она движима иррациональными целями и действиями людей.

В последнее десятилетие финансовые аналитики стали чаще обращаться к искусственным нейронным сетям – математическим моделям и их программным или аппаратным реализациям, построенным по упрощённой схеме функционирования прямого вдохновителя этой модели – биологической нейронной сети – сети нервных клеток живого организма. Возникло это понятие при изучении протекающих в мозге при мышлении процессах, и последующих попытках смоделировать эти процессы. В конечном итоге такие модели стали популярны в практических задачах прогнозирования. В отличие от привычного термина «программирование», по отношению к нейронным сетям применимо слово «обучение». Возможность обучения – это одно из, если не самое главное, преимущество нейронных сетей перед традиционными алгоритмами. С технической стороны обучение заключается в нахождении коэффициентов связи между нейронами. В процессе обучения нейронная сеть способна выявлять не тривиальные зависимости между входными и выходными данными, выполнять обобщение. Возможности нейронных сетей к прогнозированию следуют из умения обобщать и выделять скрытые зависимости между входными данными. После начального обучения сеть способна предсказать будущее значение некой последовательности на основе нескольких предыдущих значений и/или иных существующих факторов. Важно

отметить, что прогнозирование возможно только тогда, когда предыдущие изменения действительно в какой-то степени определяют будущее. Например, прогнозирование котировок акций на основе котировок за прошлый месяц будет успешным, а прогнозирование результатов литере на основе данных за любой промежуток времени наверняка не даст никаких результатов.

Рассмотрим на практике применение метода прогнозирования с помощью нейронных сетей. Для примера возьмём данные индекса ММВБ времён мирового экономического кризиса в период с 01.10.2008 по 03.04.2009. Задача состоит в том, что на основе представленной статистической информации необходимо сделать прогноз на 10 дней. Как видно из графика (рис.1), с 01.10.08 по 28.10.08 индекс ММВБ «просел» примерно на 540 пунктов. После чего последовал рост до максимальной отметки в около 870 пунктов. Далее, некоторое время, рынок находился в боковом тренде, затем наметилась восходящая тенденция. В данном примере будем строить прогноз для одной переменной (остальные аналогично), но для того, чтобы выбрать ту из четырех переменных, которая наиболее сильно поможет спрогнозировать остальные, построим матрицу парных корреляций.



Рис.1

Итак, построив матрицу парных корреляций (табл.1), делаем вывод о том, что переменная LOW наиболее сильно коррелирует с остальными. Дальнейшее прогнозирование будем производить с этой переменной.

Таблица 1 – Корреляции (MICEX)

	OPEN	HIGH	LOW	CLOSE
OPEN	1,00	0,98	0,97	0,93
HIGH	0,98	1,00	0,96	0,96
LOW	0,97	0,96	1,00	0,98
CLOSE	0,93	0,96	0,98	1,00

Нейронные сети, являющиеся по своей сути, нелинейными способны с любой степенью точности аппроксимировать произвольную непрерывную функцию, независимо от наличия или отсутствия периодичности или цикличности. Так как временной ряд представляет собой непрерывную функцию (в реальных условиях нам известно только значение этой функции в некотором конечном множестве точек, но её легко непрерывно продолжить на весь рассматриваемый отрезок), то применение нейронных сетей корректно и оправдано.

С помощью пакета STATISTICA построим тысячу нейронных сетей различной конфигурации, обучим их и выберем десятку наилучших.

В результате идентификации процесса построения сетей мы получили следующие результаты: выбранные сети, как можно заметить, имеют различные конфигурации (табл.2).

Таблица 2 – Тестирование сетей Мастером решений (MICEX_081001_090403)

	Архитектура	Пронзв. обуч.	Контр. пронзв.	Тест. пронзв.	Ошибка обуч.	Контр. ошибка	Тест. ошибка
1	МП s40 1:40-2-1:1	0,231126	0,270568	0,327128	0,061305	0,072517	0,082303
2	РБФ s40 1:40-10-1:1	0,323598	0,340073	0,293273	0,004162	0,004423	0,003542
3	Линейная s40 1:40-1:1	0,040462	1,751618	2,460311	0,010732	0,477302	0,660365
4	РБФ s40 1:40-16-1:1	0,311351	0,337140	0,316209	0,004005	0,004389	0,003917
5	РБФ s40 1:40-25-1:1	0,156097	0,281670	0,249106	0,002008	0,003719	0,003042
6	РБФ s40 1:40-25-1:1	0,146273	0,276806	0,185631	0,001881	0,003625	0,002385
7	РБФ s40 1:40-26-1:1	0,193419	0,253628	0,218406	0,002488	0,003302	0,002634
8	МП s40 1:40-4-1:1	0,203810	0,253800	0,403671	0,054061	0,072361	0,099805
9	МП s40 1:40-3-1:1	0,315956	0,249358	0,393732	0,083822	0,067392	0,101360
10	МП s40 1:40-2-1:1	0,443478	0,221179	0,418273	0,118314	0,059280	0,105905

В последствии обучения была найдена нейронная сеть (рис. 2), соответствующая модели под номером 7 (см. таблицу 2) с хорошей производительностью (её регрессионное отношение 0,253628, а ошибка: 0,003302). Стоит отметить, что производительность сетей архитектуры РБФ (Радикально Базисной Функции) в среднем хуже сетей на базе Многослойного Персептрона, что объясняется тем, что сети с архитектурой РБФ плохо экстраполируют данные (это связано с насыщением элементов скрытой структуры). Для оценки достоверности модели 7 построим гистограмму частот (рис. 3). Данная гистограмма является наиболее симметричной в сравнении с другими моделями, что в свою очередь подтверждает стандартные предположения о нормальности остатков. Следуя из вышеперечисленного модель 7 больше всего подходит для заданного временного ряда.




Рис.2




Рис.3

Осуществим проекцию для прогнозирования временного ряда. В результате имеем прогноз (рис.4, табл.3). Как видно из графика, нейронная сеть верно спрогнозировала направление тренда. Так как исходный набор данных выбран в период мирового экономического кризиса требовать более точных данных от этого метода анализа некорректно.




Рис.4

Таблица 3

Дата	Прогноз	Реальные данные
06/04/09	824,5331	829,24
07/04/09	829,2901	815,96
08/04/09	832,4234	821,1
09/04/09	836,3328	882,57
10/04/09	839,5387	905,6
13/04/09	841,7281	902,84
14/04/09	842,0062	892,76
15/04/09	842,4472	892,8
16/04/09	843,0414	902,75
17/04/09	841,5117	917,11

Как и предполагалось, нейронные сети дали хороший результат. Во многом это обусловлено сложностью и нелинейностью структуры данного ряда, в то время как классические методы рассчитаны на применение к рядам с более заметными и очевидными структурными закономерностями. Но даже, несмотря на все видимые положительные качества нейронных сетей не стоит считать их некоей «панацеей». Во-первых, нейронные сети являются «черным ящиком», который не позволяет в явном виде определить вид зависимостей между членами ряда. Таким образом, конкретную нейронную сеть можно «научить» строить прогноз лишь на строго фиксированное количество шагов вперед (которое мы указываем в спецификации этой сети), следовательно, такие нейронные сети сильно зависимы от типа задачи. Во-вторых, при наличии явной линейности, простоты структуры в задаче, способность нейронных сетей к обобщению оказывается более слабой по отношению к классическим методам. Объясняется это как раз нелинейностью сетей по своей сути.

В общем случае для достижения наилучшего результата необходимо использовать нейронные сети в совокупности с грамотной стратегией управления.